

INSTITUTO FEDERAL DO RIO GRANDE DO SUL - CAMPUS ERECHIM

3º SEMESTRE TEC. A. D. S.

**INFRAESTRUTURA EM ENGENHARIA DE DADOS:
PIPELINES, ORQUESTRAÇÃO E O PAPEL DOS CONTAINERS**

Atividade de Pesquisa

Emanuel D'Agostini Tonial

2026

1 TEMA CENTRAL

O presente trabalho tem como tema central a **infraestrutura de pipelines e orquestração em Engenharia de Dados**, com ênfase no impacto do uso de containers na eficiência, escalabilidade e confiabilidade dos processos de tratamento e movimentação de dados em ambientes modernos de grande escala.

2 PERGUNTAS DE PESQUISA IDENTIFICADAS

A partir do tema central, foram formuladas três perguntas de pesquisa, listadas a seguir:

1. O uso de containers afeta a eficiência das pipelines de dados em ambientes de engenharia de dados de grande escala?
2. Existe grande impacto das pipelines de dados na qualidade e escalabilidade dos dados em empresas orientadas a dados?
3. Como a orquestração de pipelines em infraestruturas de nuvem altera o uso de recursos computacionais?

Após avaliação das três perguntas quanto à especificidade, mensurabilidade e disponibilidade de literatura acadêmica, a **Pergunta 1** foi selecionada como foco principal do trabalho, por apresentar maior precisão técnica e maior volume de estudos disponíveis no Consensus.

3 PERGUNTA DE PESQUISA SELECIONADA

O uso de containers afeta a eficiência das pipelines de dados em ambientes de engenharia de dados de grande escala?

4 CONSENSO ACADÊMICO

A consulta realizada na plataforma Consensus, ferramenta de busca acadêmica baseada em inteligência artificial, revelou um **consenso positivo e bem estabelecido** a respeito do tema. A literatura acadêmica indica consistentemente que containers aumentam a eficiência de pipelines de dados, especialmente em cenários distribuídos e de grande volume.

Os estudos apontam ganhos expressivos em throughput, latência, escalabilidade e reprodutibilidade, com overhead de performance classificado como pequeno ou desprezível para tarefas de média e alta duração. A única ressalva recorrente diz respeito ao custo inicial para configurar o ambiente e instâncias os containers.

Entre os achados mais relevantes identificados pelo Consensus, destacam-se:

- Pipelines genômicas containerizadas com Docker apresentaram impacto mínimo no tempo de execução, com o pequeno custo sendo amplamente compensado pela facilidade de empacotamento e reprodutibilidade do ambiente (DI TOMMASO et al., 2015);
- Pipelines IoT containerizadas em Kubernetes com autoscaling alcançaram aumento de throughput entre 1,31x e 2,4x, com redução de latência entre 32x e 80x frente a alocações estáticas de recursos (AURANGZAIB et al., 2022);

- Um modelo de pipeline encapsulado em containers reduziu tempos de resposta entre 43% e 91% em comparação a pipelines em memória e outras engines (SANTIAGO-DURAN et al., 2020);
- Em ambientes de ETL na área da saúde, a combinação de PySpark e Docker trouxe ganhos relevantes de tempo de processamento, uso de recursos e escalabilidade (SOLTANMOHAMMADI; HIKMET, 2024).

5 CONSIDERAÇÕES MAIS IMPORTANTES A PESQUISAR

Com base no consenso acadêmico e nas lacunas identificadas na literatura, as seguintes dimensões se mostram centrais para o aprofundamento da pesquisa:

Dimensão	O que investigar
Performance	Impacto real no tempo de execução e throughput em diferentes cargas e tipos de dados
Escalabilidade	Como o autoscaling via Kubernetes responde a variações súbitas de demanda em pipelines de dados
Reprodutibilidade	Consistência de resultados entre ambientes de desenvolvimento, teste e produção
Trade-offs operacionais	Overhead de startup de containers e curva de aprendizado para equipes de engenharia
Contexto setorial	Variações de resultado entre setores: saúde, IoT, machine learning e analytics corporativo
Ferramentas de orquestração	Comparação entre Apache Airflow, Prefect e Dagster em ambientes containerizados

6 JUSTIFICATIVA

A crescente adoção de arquiteturas orientadas a dados nas organizações torna a eficiência das pipelines de dados um fator crítico de competitividade e inovação. Nesse contexto, a containerização emerge como uma das principais estratégias de infraestrutura em engenharia de dados, impactando diretamente a velocidade de processamento, a confiabilidade operacional e a capacidade de escalonamento dos sistemas. Estudos recentes demonstram ganhos expressivos: pipelines de dados em tempo real para Internet das Coisas (IoT), containerizadas em Kubernetes, alcançaram aumento de throughput entre 1,31x e 2,4x, com redução de latência de até 80× frente a alocações estáticas de recursos (AURANGZAIB et al., 2022). Em ambientes de extração, transformação e carga (ETL) na área da saúde, a combinação de PySpark e Docker resultou em ganhos significativos de tempo de processamento e uso de recursos (SOLTANMOHAMMADI; HIKMET, 2024). Além da performance bruta, containers oferecem benefícios operacionais relevantes para equipes de engenharia de dados: portabilidade entre ambientes multi-cloud, isolamento de dependências, modularidade de estágios de pipeline e recuperação automática de falhas via orquestradores como o Kubernetes, características fundamentais para pipelines confiáveis em produção (GANDHARI, 2025; TIWARI, 2025). Compreender como e sob quais condições esses ganhos se materializam é, portanto, essencial para orientar decisões estratégicas de infraestrutura em times de engenharia de dados modernos, especialmente diante da expansão acelerada de volumes de dados e da diversificação das fontes e destinos de informação nas organizações contemporâneas.

REFERÊNCIAS

AURANGZAIB, R. et al. Scalable Containerized Pipeline for Real-time Big Data Analytics. In: IEEE INTERNATIONAL CONFERENCE ON CLOUD COMPUTING TECHNOLOGY AND SCIENCE (CloudCom), 2022. Anais [...]. [S. l.]: IEEE, 2022. p. 25-32.

DI TOMMASO, P. et al. The impact of Docker containers on the performance of genomic pipelines. PeerJ, v. 3, 2015.

GANDHARI, S. Kubernetes for Data Engineering: Orchestrating Reliable ETL Pipelines in Production. The American Journal of Engineering and Technology, 2025.

SANTIAGO-DURAN, M. et al. A gearbox model for processing large volumes of data by using pipeline systems encapsulated into virtual containers. Future Generation Computer Systems, v. 106, p. 304-319, 2020.

SOLTANMOHAMMADI, E.; HIKMET, N. Optimizing Healthcare Big Data Processing with Containerized PySpark and Parallel Computing: A Study on ETL Pipeline Efficiency. Journal of Data Analysis and Information Processing, 2024.

TIWARI, S. Architecting Resilient Data Pipelines: Best Practices for Scalable ETL in Multi-Cloud Environments. Journal of Computer Science and Technology Studies, v. 7, n. 12, 2025.